

分类号

密级

# 重庆邮电大学研究生学位论文 开题报告

中文题目

基于核逻辑回归的遥感

图像分类方法

英文题目

**Remote Sensing Image Classification**

**based on Kernel Logistic Regression**

学 号

**S170231053**

姓 名

唐建烱

学位层次

硕士研究生

学位类别

工程硕士

学科专业

计算机技术

研究方向

智能信息处理

指导教师

雷大江 副教授

完成日期

**2018 年 12 月 20 日**

## 一、选题依据

### 1.1 研究背景、目的和意义

#### 1.1.1 研究背景

随着遥感技术的发展,各种传感器每天都能采集到大量的遥感图像,人们可以从中获得大量的有用数据和信息。高分辨率的遥感图像能提供丰富的光谱信息和空间纹理信息,在资源调查、自然灾害检测、天气气象预告、土地利用分类和国防安全上有着广泛的应用。但是由于遥感图像数据量大,目标类型多样且图像会受天气、光线等因素的影响有大量的噪点,传统的依靠人工来对大量遥感图像中的地物进行识别检测和分类显然是不可行的。

目前对遥感图像地物分类存在训练样本特征维度高,异构信息冗杂,含有大量的噪声波段和非线性结构数据,传统的分类算法很难达到精度要求。逻辑回归(Logistic Regression, LR)算法是统计分析、机器学习和数据挖掘领域的一个经典分类算法,用于估计事件发生的可能性,输出等价于模型预测某个数据点属于正类的概率估计。它是一种线性的分类算法,具有求解速度快、预测结果可解释性强的特点,它为探索性解释数据提供了一个有用的概率模型。但是,一般的 LR 只能用于线性分类,对于非线性的特征数据分类就十分的困难。Logistic 回归经过核化扩充之后的分类器称之为核 Logistic 回归(Kernel logistic regression, KLR),这样就变成了可用于非线性特征数据分类的分类器<sup>[1]</sup>。通过将原数据的样本映射到一个高维或无穷维的特征空间,使得样本在这个特征空间内线性可分<sup>[2, 3]</sup>。虽然此过程的映射规则通常是不可知的,但是可以用核函数(Kernel function)去代替特征空间上的内积运算<sup>[4]</sup>,因此并不需要知道此特征空间里特征向量的具体表达形式<sup>[5, 6]</sup>。核方法<sup>[7]</sup>在近年来机器学习领域十分流行,尤其是基于统计学习理论的支持向量机的成功<sup>[8]</sup>,由此产生了多种基于核函数的方法<sup>[9]</sup>,并且被广泛的应用于模式识别、文本分类、信号处理等多个领域<sup>[10]</sup>。

KLR 也是一个凸优化问题,局部最优解一定是全局最优解<sup>[11]</sup>。而对于一个凸优化问题,可以运用梯度法或牛顿迭代法进行求解<sup>[12]</sup>,但是该两种方法在每次迭代过程中都需要对一个  $n \times n$  的核矩阵进行求逆等运算,其中  $n$  表示样本个数,通常  $n$  的数量达到几千个时,计算时间代价就变得非常的大,甚至难以接受,其时

间复杂度为 $O(n^3)$ 。在支持向量机的凸二次规划问题求解中, Platt 等人提出了序列最小最优化算法 (Sequential minimal optimization, SMO) [13], 基于此算法思想的启发, Keerthi 等人又给出了一种用于计算 KLR 的快速对偶算法[14], 该算法不需要将整个核矩阵带入迭代步骤里进行计算, 每一次迭代只优化序列里的两个值, 避免了对核矩阵进行求逆等操作, 因此迭代的计算代价十分的小。

核矩阵通常都是稠密矩阵, 其存储和计算代价都非常的高, 存储稠密矩阵需要 $O(n^2)$ 的空间, 而计算这样的矩阵则需要 $O(n^2m)$ 的代价, 这里 $n$ 和 $m$ 分别代表了样本的个数和维度[15], 通常样本数都是上万甚至上百万, 而特征维度都是上千左右。因此最常用的解决方法是用有限的内存来计算得到一个近似的核矩阵[16, 17], 这种方法不仅解决了内存问题, 也加快了核矩阵的计算。目前已有多种核近似方法被提出[18, 19], 其中 Nystrom 方法的应用最为广泛, 也是之后很多求解近似矩阵算法的基础[20]。Nystrom 方法的主要思想是通过降低秩来得到原始矩阵 $K$ 的近似矩阵 $\tilde{K}$ , 相当于从 $K$ 中随机取 $m$ 行 $m$ 列, 则 $\tilde{K} = K_{n,m}K_{m,m}^{-1}K_{m,n}$ , 其中 $K_{n,m}$ 是原始矩阵  $K$  中的 $n \times m$ 块矩阵, 而 $m \ll n$ 。

### 1.1.2 研究目的

通过分类算法对遥感图像进行像素点级别的分类。采用多核学习方法, 经过多个核函数将不同类型的特征数据映射到多个高维特征空间上, 使得数据在新的组合空间上能够更加准确、合理的表达, 进而去判别图像中地物所属的类别。

### 1.1.3 研究意义

(1) 遥感图像分类是提取遥感信息的一种重要手段, 常用于军事侦察、导弹预警、武器制导、军事测绘、道路提取等。而遥感数据的维度很高, 数据类型也通常是异构的, 含有大量的冗余信息[21], 普通的分类器很难达到分类精度的需求, 而将多核学习应用到遥感图像分类上能很好的提高分类效果。

(2) 核逻辑回归算法是逻辑回归算法的一种改进, 通过核方法将其扩充成了可用于非线性特征的分类器, 可以作用于一些非线性特征的数据集, 具有一定的学术意义和研究价值。

## 1.2 国内外研究现状

### 1.2.1 核方法研究

近十多年来, 由 Vapnik 等提出的支持向量机(Support Vector Machine, SVM)被广泛的应用于分类任务中, 核方法最早就是应用在 SVM 上, 通过引入核函数来解决非线性分类问题<sup>[22]</sup>。在 SVM 获得巨大的成功中, 核方法扮演了非常重要的角色。进一步的, 核方法被应用到了其他传统的学习算法中去, 可以很方便的把线性算法转化为非线性算法。例如: 核主成分分析(Kernel PCA)<sup>[23]</sup>、核 Fisher 判别分析(Kernel FDA)<sup>[24]</sup>、核聚类分析等等, 这些基于核的学习算法都简称为核方法。只采用一个基本核的学习方法称之为单核学习, 而相比于单个核函数, 多核模型具有更高的灵活性。多核学习方法根据不同的分类标准有不同的分类方式, 按照多核函数的构造方法和特点的不同, 可以将多核学习方法大致分成三大类别: 合成核方法、多尺度核方法、无限核方法。而多核学习理论早期大体上分为: 基于 Boosting 的多核组合模型学习方法, 基于半定规划(Semi-definite programming, SDP)的多核学习方法, 基于二次约束型二次规划(Quadratically constrained quadratic program, QCQP)的学习方法, 基于半无限线性规划(Semi-definite linear program, SILP)的学习方法和基于超核(Hyper kernels)的学习方法等<sup>[25]</sup>。接着为了达到更好的收敛效果和得到更好的解, 2012 年 Vishwanathan 又提出 SPG-GMKL<sup>[26]</sup>算法, 同时提出了多核的 Product 组合。而近年来出现的简单多核学习(Simple MKL)方法<sup>[27]</sup>以及基于中心对齐的学习核算法(Algorithms for Learning Kernels Based on Centered Alignment)<sup>[28]</sup>都是比较流行的多核学习方法。而在视觉识别任务中, 通过在统一的内核空间中加入稀疏模型往往能取得很好的效果<sup>[29]</sup>。

Logistic regression 算法是一种广义的线性回归分析模型, 为了解决非线性分类问题, 于是将核方法引入到了该分类器中, 便出现了核逻辑回归(Kernel logistic regression, KLR)。但是由于引入了核矩阵, 迭代求解 KLR 变得非常的缓慢。受到 Platt 的序列最小最优算法(Sequential Minimal Optimization, SMO)的启发, Keerthi 基于对偶理论<sup>[30]</sup>提出了求解 KLR 的快速对偶算法, 避免了将核矩阵带入到迭代过程中去运算, 从而极大的减少了计算开销。但是随着数据量的不断增大, 核矩阵的计算也会影响整个算法的开销, 并且将整个数据样本都通过核函数映射到高维空间上去, 会带入一些冗余信息。因此, 矩阵的近似求解方法被广泛的应用在了求解核矩阵上, 如: Nystrom 方法, Fastfood 方法<sup>[31]</sup>等。通过这些方法可以加速核矩阵的求解, 利用低秩近似又可以去掉原始数据中的一些冗余信息。

### 1.2.2 遥感图像分类研究

随着卫星遥感图像和航空遥感图片分辨率的不断提高,人们可以从遥感图像中获得更多的有用的数据和信息。遥感技术应用的核心问题是根据地物辐射电磁辐射强弱在遥感图像上表现的特征,判读识别地面物体的类属及其分布特征。遥感图像特征取决于遥感探测通道、地物光谱特征、大气传播特征及传感器的响应特征等因素。只要了解这些因素对遥感图像特征的影响,则可按图像特征判读地面物体的属性及其分布范围,实现遥感图像的分类识别。目前图像识别和分类方法通常都是采用神经网络。但是在实际应用中,遥感图像的数据的采集和标定是较困难的,获取的已标定的训练样本集较小,卷积神经网络需要动辄百万级的训练样本,小样本训练效果往往不能满足需求,如何从小量的数据中生成良好的神经网络或者对小样本异构特征图像进行识别和分类将是未来的研究方向<sup>[32]</sup>。此外迁移学习也可以解决遥感数据样本少的问题。而多核学习则可以将不同类型的异构特征进行不同的映射处理,充分利用了遥感图像的光谱特征和空间结构特征,能在有效的时间内得到可观的分类准确率。对于遥感图像的分类,主要有基于像素点的分类方法和面向对象的分类方法,目前有 Dr. J. Li 提出的基于多核学习的高光谱图像分类框架 MLR-GCK<sup>[33]</sup>和基于超像素的多核高光谱图像分类算法<sup>[34]</sup>都取得了很好的分类效果。

### 1.3 当前存在的主要问题

通过对当前遥感图像分类的研究现状进行思考,可以得出其存在以下几个方面的问题:

(1) **核逻辑回归算法计算的时间开销大。**对于核逻辑回归算法的求解,通常都会引入一个稠密的核矩阵,其存储和计算代价都非常的高,存储稠密矩阵需要  $O(n^2)$  的空间,而计算这样的矩阵则需要  $O(n^2m)$  的代价,这里  $n$  和  $m$  分别代表了样本的个数和维度。如果直接将全部样本加载到内存中计算所需的核矩阵,通常会引起内存溢出,很难处理大规模的数据集。而在求解核逻辑回归算法的时候,如果采用梯度下降或者牛顿迭代法这样的迭代求解算法,在其迭代过程中核矩阵都会参与迭代运算,并且还可能涉及到对核矩阵求逆等操作。由于核矩阵的大小是和样本个数成正比的,当数据达到一定规模的时候,对大型的核矩阵进行矩阵迭代运算开销十分的大,有时候甚至难以接受。

(2) **多核学习加权系数选择问题。**多核学习是将不同类型特征的多个核函数进行组合来得到新的多核函数，而多核组合方法主要是将基本的核函数直接进行求和或者加权求和，这样就很难找到可靠的加权系数，并且有可能丢失掉原始数据的某些特征信息。

(3) **遥感图像中不同类型特征的应用。**对于遥感图像多分类问题，由于遥感图像中不仅包含光谱特征还有空间信息特征，如果只利用其中的光谱特征对其像素点进行分类，精度通常难以达到需求。

## 二、研究目标和主要研究内容

### 2.1 研究目标

(1) **拟提出一种快速核逻辑回归算法。**针对核逻辑回归算法求解缓慢的问题，拟采用序列最小最优化算法进行求解。在核矩阵的求解中，则采用低秩近似的方法去近似求解核矩阵，从而降低算法求解的整体时间复杂度。

(2) **拟提出一种多核多元逻辑回归算法。**将核逻辑回归算法扩展成多分类器，使其能适用于多类别的分类任务，再引入多核学习，拟从效率和精度上进行改进。

(3) **拟提出一种基于核逻辑回归算法的遥感图像分类方法。**由于遥感图像的多特征特性，通过设计多核多元逻辑回归算法去提升分类效果。

(4) **拟设计一个遥感图像分类的原型系统。**通过提前训练好模型，然后将上传的遥感图像进行分类，识别图像中地物的类别并展示出来。

### 2.2 主要研究内容

#### 2.2.1 快速核逻辑回归算法

逻辑回归是一种有监督的常用分类算法，但是不能处理非线性特征的数据。为了解决非线性数据分类问题，通过核方法将逻辑回归进行核扩充后将原始样本映射到高维空间上去再进行分类。在求解核逻辑回归算法过程中，为了避免将核矩阵带入到迭代运算过程中，于是采用 SMO 优化算法去求解，减少算法的时间复杂度。引入核方法后，在求解核逻辑回归(KLR)时，随着样本规模不断扩大，核方法的应用越来越受限制。核矩阵通常都是稠密矩阵，其存储和计算代价都非常的高，为了解决这个问题，采用 Nystrom 方法去低秩近似核矩阵，一方面不仅能

减少核矩阵的运算开销，另一方面还能通过低秩减少数据中的冗余信息，提高分类器的精度。

**2.2.2 多核多元逻辑回归算法**

单核学习的核函数只有一个，其结构单一，对于某些具有不同类型特征的异构数据，如果都统一采用一个核函数，映射到同一个特征空间上去，显然是不合理的。多核学习则是给定一些基本的核函数，对于每一个基核函数又可以指定不同的参数，最后通过它们的加权线性组合来得到最终的复核函数。由于融合了多个核函数，使得不同类型的特征数据映射到不同的高维空间中能更好的表达。如何得到多核学习的线性组合权重，最经典的就是 simpleMKL，被应用在了计算机各个领域。为了使多核学习应用地更广，应对各种特征组合、各种样本量级，后来提出了 GMKL，最优化方法用的是 PGD（Projected Gradient Descend）。而基于中心对齐的学习核算法 (Algorithms for Learning Kernels Based on Centered Alignment)<sup>[28]</sup>是比较流行的多核学习方法，通过学习能得到一组核函数的权重系数，由此可以组合成新的核函数。

一般的逻辑回归只能作用于二分类，为了适用于多类别的多分类任务，需要将其扩充成多元逻辑回归。单核学习对于某些具有不同类型的数据不够适用，于是将多核学习引入到多元逻辑回归中，并增加稀疏项，提高算法的效率和精度。

**2.2.3 基于核逻辑回归算法的遥感图像分类方法**

对于遥感图像数据，由于数据的维度很高，数据类型也通常是异构的，容易产生大量的冗余信息。如果在选取核函数的时候，只选用一种核函数会导致遥感图像丰富的信息难以被有效利用。为了解决这个问题，于是提出了基于多核多元稀疏逻辑回归算法的遥感图像分类方法，经过多个核函数将不同类型的特征数据映射到多个高维特征空间上，最终使得数据在新的高维组合空间上能够更加准确、合理的表达。

**2.2.4 实现遥感图像分类的原型系统**

利用多核多元稀疏逻辑回归算法实现遥感图像分类的原型系统。

**三、拟解决关键问题及其研究方法**

**3.1 拟解决关键问题**

### (1) 计算时间开销问题

针对核逻辑回归算法求解的开销问题，拟采用SMO算法联合Nystrom方法去联合求解。SMO算法避免了将整个核矩阵带入到迭代公式中，Nystrom通过低秩去近似求解所需的核矩阵，并且去掉了数据中部分冗余的信息，提高了分类精度。

### (2) 多核学习加权系数选择问题

针对多核函数的选取和线性组合问题，拟采用基于中心对齐的align方法去学习内核的线性组合，从而得到所需的复合核函数。

## 3.2 拟采取的研究方法

### (1) 拟采取SMO算法联合低秩近似方法快速求解核逻辑回归

为了解决核逻辑回归计算时间开销问题，拟采用SMO算法联合Nystrom低秩近似方法去加速求解核逻辑回归算法。

假设有数据集  $D = \{(\mathbf{x}^{(i)}, y^{(i)})\}, i = 1, \dots, n, \mathbf{x}^{(i)} \in \mathbb{R}^m, y \in \{0,1\}$ , 输入向量为  $\mathbf{x}_i = (x^{(1)}, \dots, x^{(m)})$ , 类标签  $y$  为二值函数。由于二分类结果是1或-1, 即  $y \in \{1,-1\}$ , 则对于给定样本  $\mathbf{x}^{(i)}$ , 它属于类别  $y$  的概率可以表示为:

$$P(y|\mathbf{x}) = h_w \left( \frac{1}{1 + e^{-w^T \mathbf{x}}} \right) \quad (1)$$

假定给的样本是独立的，便可以构造出似然函数，然后使用极大似然估计 (Maximum Likelihood, ML) 的思想来求解参数。这里再对似然函数取对数，得到：

$$\log L(w) = \sum_{i=1}^n [y_i \log h_w(x) + (1 - y_i) \log(1 - h_w(x))] \quad (2)$$

根据表达定理:  $w^* = \sum_{i=1}^n \alpha_i \varphi(x_i)$ , 此处的  $\varphi(x_i)$  为  $x_i$  在特征空间的投影。将特征投影到高维空间并引入  $L_2$  正则项，于是最终得到 KLR 的损失函数：

$$\text{Loss}(\alpha) = -\frac{1}{n} \sum_{i=1}^n (y_i \ln p_i + (1 - y_i) \ln(1 - p_i)) + \frac{\lambda}{2} \alpha^T K \alpha \quad (3)$$

为了减少 KLR 算法中核矩阵  $\mathbf{K}$  的计算时间，可以利用 Nystrom 方法去近似  $\mathbf{K}$ :

$$\mathbf{K} \approx \tilde{\mathbf{K}} = \tilde{\mathbf{U}} \tilde{\Lambda} \tilde{\mathbf{U}}^T = \sum_{i=1}^p \tilde{\lambda}_i^{(n)} \tilde{\mathbf{u}}_i^{(n)} (\tilde{\mathbf{u}}_i^{(n)})^T \quad (4)$$

然后将近似的  $\tilde{\mathbf{K}}$  带入 SMO 算法中，从而节省了整体的计算开销，还提高了分类的准确度。



## (2) 拟采用基于中心对齐的 align 方法学习多核权重系数

首先将核逻辑回归扩充成多元核逻辑回归，使其能适用于多分类任务。接着为了解决引入多核学习后，如何确定构成复合核的权重系数问题，拟采用基于中心对齐的 align 方法去自动学习多核权重系数。通过选取不同参数或不同类型的核函数作为基核，然后通过中心对齐算法去学习这些基核的权重系数，最后构成所需要的复合核函数，将其扩充到多分类器中。

$$\mathbf{K}_{c\mu} = \sum_{q=1}^p \mu_q \mathbf{K}_{cq} \quad (5)$$

这里 $\mu_q$ 为通过中心对齐的 align 方法学习得到到权重系数。

## (3) 拟利用遥感图像中的空间信息特征和光谱特征进行分类

针对遥感图像的高维度异构特征，首先从高光谱图像中提取出空间信息特征，然后可以采用适当的降维方法去降低特征维度，最后结合其光谱特征通过多核学习去提升遥感图像分类的准确率。

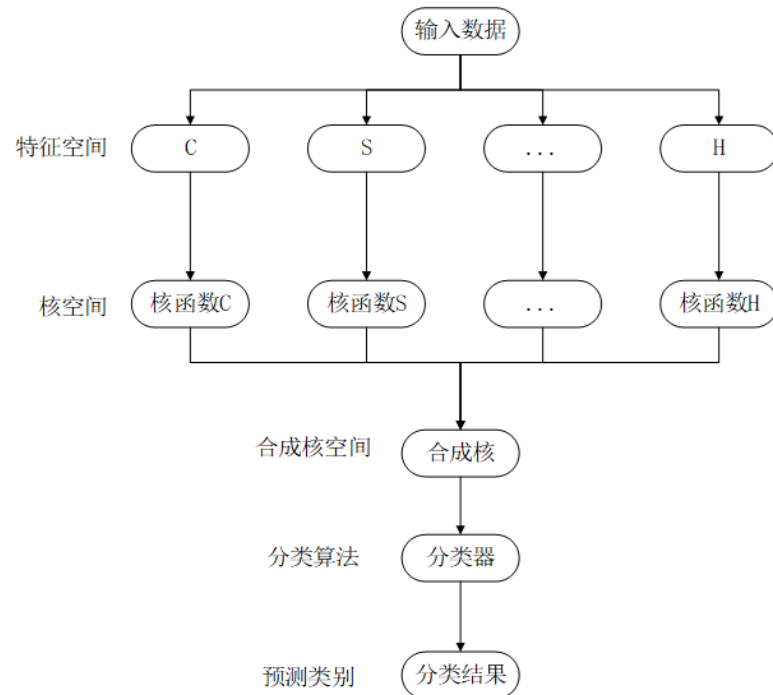


图 1 多核学习算法基本流程图

#### (4) 遥感图像分类的原型系统

拟采用 B/S 架构实现基于多核多元稀疏逻辑回归算法的遥感图像分类原型系统，通过提前预训练好模型，然后对新上传的遥感图像进行像素点级别的分类，最后将图像中的地物以不同的颜色标注并可视化。

### 3.3 可能的创新

(1) 提出一种基于SMO和Nystrom方法的加速求解核逻辑回归算法，具有更快的求解速度，和更高的分类精度。

(2) 提出一种基于中心对齐的align方法的多核逻辑回归算法，通过多核学习将遥感图像中不同类型的特征映射到不同的维度空间。

#### 参考文献:

- [1] Ngufor C,Wojtusiak J.Extreme logistic regression[J]. Advances in Data Analysis and Classification, 2016, 10(1):27-52.
- [2] Mackenzie C A,Trafalis TB,Barker K. A Bayesian beta kernel model for binary classification and online learning problems[J].Statistical Analysis and Data Mining, 2014, 7(6):434-449.
- [3] Yang L,Qian Y. A sparse logistic regression framework by difference of convex functions programming[J]. Applied Intelligence, 2016, 45(2):1-14.
- [4] Bao J, Chen Y, Yu L, et al. A multi-scale kernel learning method and its application in image classification[J]. Neurocomputing, 2017, 257: 16-23.
- [5] Avron H, Clarkson K L, Woodruff D P. Faster kernel ridge regression using sketching and preconditioning[J]. SIAM Journal on Matrix Analysis and Applications, 2017, 38(4): 1116-1138.
- [6] Koppel A, Warnell G, Stump E, et al. Parsimonious online learning with kernels via sparse projections in function space[C]. Acoustics, Speech and Signal Processing (ICASSP), 2017 IEEE International Conference on. IEEE, 2017: 4671-4675.
- [7] Kang Z, Peng C, Cheng Q. Kernel-driven similarity learning[J]. Neurocomputing, 2017, 267: 210-219.
- [8] Vapnik V. The nature of statistical learning theory[M]. Springer science & business media, 2013.

- [9] Zhou J, Duan B, Huang J, et al. Incorporating prior knowledge and multi-kernel into linear programming support vector regression[J]. *Soft Computing*, 2015, 19(7): 2047-2061.
- [10] Shaobo L, Jinshan Z. Fast Learning With Polynomial Kernels[J]. *IEEE Transactions on Cybernetics*, 2018:1-13.
- [11] Boyd S, Vandenberghe L. *Convex optimization*[M]. Cambridge university press, 2004.
- [12] Maalouf M, Trafalis T B, Adrianto I. Kernel logistic regression using truncated Newton method[J]. *Computational management science*, 2011, 8(4): 415-428.
- [13] Platt J C. 12 fast training of support vector machines using sequential minimal optimization[J]. *Advances in kernel methods*, 1999: 185-208.
- [14] Keerthi S S, Duan K B, Shevade S K, et al. A fast dual algorithm for kernel logistic regression[J]. *Machine learning*, 2005, 61(1-3): 151-165.
- [15] Rossmann T. The average size of the kernel of a matrix and orbits of linear groups[J]. *Proceedings of the London Mathematical Society*, 2018, 117(3): 574-616.
- [16] Ubaru S, Saad Y, Seghouane A K. Fast estimation of approximate matrix ranks using spectral densities[J]. *Neural computation*, 2017, 29(5): 1317-1351.
- [17] Stražar M, Curk T. Learning the kernel matrix via predictive low-rank approximations[OL]. *arXiv:1601.04366*, 2016.
- [18] Phillips J M, Tai W M. Improved coresets for kernel density estimates[C]. *Proceedings of the Twenty-Ninth Annual ACM-SIAM Symposium on Discrete Algorithms*. Society for Industrial and Applied Mathematics, 2018: 2718-2727.
- [19] Needell D, Srebro N, Ward R. Stochastic gradient descent, weighted sampling, and the randomized Kaczmarz algorithm[J]. *Mathematical Programming*, 2016, 155(1-2):549-573.
- [20] Pourkamali-Anaraki F, Becker S. Randomized Clustered Nystrom for Large-Scale Kernel Machines[OL]. *arXiv:1612.06470*, 2016.
- [21] Zhao W, Du S. Spectral-spatial feature extraction for hyperspectral image classification: A dimension reduction and deep learning approach[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2016, 54(8): 4544-4554.
- [22] Gower R M, Richtárik P. Randomized iterative methods for linear systems[J]. *SIAM Journal on Matrix Analysis and Applications*, 2015, 36(4): 1660-1690.

- [23] Xia J, Falco N, Benediktsson J A, et al. Hyperspectral image classification with rotation random forest via KPCA[J]. IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens, 2017, 10(4): 1601-1609.
- [24] Zhu Z B, Song Z H. A novel fault diagnosis system using pattern classification on kernel FDA subspace[J]. Expert Systems with Applications, 2011, 38(6): 6895-6905.
- [25] Gönen M, Alpaydın E. Multiple kernel learning algorithms[J]. Journal of machine learning research, 2011, 12(Jul): 2211-2268.
- [26] Jain A, Vishwanathan S V N, Varma M. SPF-GMKL: generalized multiple kernel learning with a million kernels[C]. Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining. ACM, 2012: 750-758.
- [27] Rakotomamonjy A, Bach F R, Canu S, et al. SimpleMKL[J]. Journal of Machine Learning Research, 2008, 9(Nov): 2491-2521.
- [28] Cortes C, Mohri M, Rostamizadeh A. Algorithms for learning kernels based on centered alignment[J]. Journal of Machine Learning Research, 2012, 13(Mar): 795-828.
- [29] Thiagarajan J J, Ramamurthy K N, Spanias A. Multiple kernel sparse representations for supervised and unsupervised learning[J]. IEEE transactions on Image Processing, 2014, 23(7): 2905-2915.
- [30] Lee J H, Lee G M. On optimality conditions and duality theorems for robust semi-infinite multiobjective optimization problems[J]. Annals of Operations Research, 2018, 269(1-2): 419-438.
- [31] He L, Li Y, Zhang X, et al. Incremental spectral clustering via fastfood features and its application to stream image segmentation[J]. Symmetry, 2018, 10(7): 272-289.
- [32] Xia J, Chanussot J, Du P, et al. Rotation-based support vector machine ensemble in classification of hyperspectral data with limited training samples[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(3): 1519-1531.
- [33] Li J, Marpu P R, Plaza A, et al. Generalized composite kernel framework for hyperspectral image classification[J]. IEEE transactions on geoscience and remote sensing, 2013, 51(9): 4816-4829.
- [34] Fang L, Li S, Duan W, et al. Classification of hyperspectral images by exploiting spectral-spatial information of superpixel via multiple kernels[J]. IEEE transactions on geoscience and remote sensing, 2015, 53(12): 6663-6674.

#### 四、进度安排和预期成果

##### 4.1 预期成果

攻读硕士学位期间预期获得如下成果：

- (1) 发表 1 篇中文核心期刊以上学术论文；
- (2) 或申请并受理 1 件发明专利；
- (3) 完成学位论文的撰写。

##### 4.2 进度安排

时间段	工作内容	预期成果
2018.7-2018.12	查阅相关资料，了解选题的背景意义和应用前景，确定论文选题方向。	确定研究方向
2018.12-2019.6	结合国内外研究状况，对当前的主流研究方法进行分析，形成自己的理论创新并通过仿真实验进行验证。	拟投出 1 篇论文， 并申请 1 件 发明专利
2019.7-2019.12	根据已有成果，对所选研究方向开展进一步研究，并完成系统设计和中期答辩工作。	完成所需实验结果
2019.12-2020.4	撰写毕业论文	完成毕业论文
2020.4-2020.6	毕业论文修改至定稿	答辩

##### 4.3 研究条件

硬件条件：一台装有 win10 64 位系统的台式电脑、Intel 酷睿 i5 处理器，12G 内存，2G 独立显卡。

软件条件：IDEA2017，Matlabel2017b，重庆邮电大学图书馆电子文献资源。

公共数据集：公共二分类数据集、高光谱图像数据集等。

根据已有研究条件，符合所选研究课题对软、硬件设备的要求，能够顺利开展相关研究工作。

备注：以上内容根据情况添页。

